



数据结构

Data Structure

许 蕾

xlei@nju.edu.cn



第六章 集合与字典



- 集合及其表示
- 并查集与等价类
- 字典
- 散列



6.5 散列表 (Hash Table)



- **理想的搜索方法**是可以不经过比较，**一次直接**从字典中得到要搜索的元素。
- 如果在元素存储位置与其关键码之间建立一个确定的**对应函数关系** $\text{Hash}()$ ，使得每个关键码与唯一的存储位置相对应：

$$\text{Address} = \text{Hash}(\text{key})$$

- 在**插入时**依此函数计算存储位置并按此位置存放。在**搜索时**对元素的关键码进行同样的计算，把求得的函数值当做元素存储位置，然后按此位置搜索。这就是**散列方法**。



- 在散列方法中所用转换函数叫做**散列函数** (又叫**哈希函数**)。按此方法构造出来的表叫做**散列表** (又叫**哈希表**)。
- 使用散列方法进行搜索不必进行多次关键码的比较, 搜索速度比较快, 可以**直接到达或逼近**具有此关键码的表项的实际存放地址。
- 散列函数是一个**压缩映象函数**。关键码集合比散列表地址集合大得多。因此有可能经过散列函数的计算, 把不同的关键码映射到同一个散列地址上, 这就产生了**冲突**。



- 示例：有一组表项，其关键码分别是

12361, 07251, 03309, 30976

- 采用的散列函数是

$$hash(x) = x \% 73 + 13420$$

则有 $hash(12361) = hash(07251) = hash(03309) = hash(30976) = 13444$ 。

- 即对不同的关键码，通过散列函数的计算，得到了同一散列地址。称这些产生冲突的散列地址相同的不同关键码为**同义词**。



- 由于关键码集合比地址集合大得多, 冲突很难避免。所以对于散列方法, 需要讨论以下两个问题:
 - 对于给定的一个关键码集合, 选择一个计算简单且地址分布比较均匀的散列函数, 避免或尽量减少冲突;
 - 设计解决冲突的方案。



散列函数



- **构造散列函数时的几点要求：**
 - 散列函数应是**简单**的，能在较短的时间内计算出结果。
 - 散列函数的**定义域**必须包括需要存储的全部关键码，如果散列表允许有 m 个地址时，其**值域**必须在 0 到 $m-1$ 之间。
 - 散列函数计算出来的地址应能**均匀分布**在整个地址空间中：若 key 是从关键码集合中随机抽取的一个关键码，散列函数应能以同等概率取 0 到 $m-1$ 中的每一个值。



① 直接定址法

此类函数取关键码的某个线性函数值作为散列地址：

$$Hash(key) = a * key + b \quad \{a, b \text{ 为常数}\}$$

这类散列函数是**一对一**的映射，一般不会产生冲突。但它要求散列地址空间的大小与关键码集合的大小相同。



- **示例：有一组关键码如下：{ 942148, 941269, 940527, 941630, 941805, 941558, 942047, 940001 }。散列函数为**

$$\text{Hash}(\text{key}) = \text{key} - 940000$$

$$\text{Hash}(942148) = 2148 \quad \text{Hash}(941269) = 1269$$

$$\text{Hash}(940527) = 527 \quad \text{Hash}(941630) = 1630$$

$$\text{Hash}(941805) = 1805 \quad \text{Hash}(941558) = 1558$$

$$\text{Hash}(942047) = 2047 \quad \text{Hash}(940001) = 1$$

- **可以按计算出的地址存放记录。**



② 数字分析法

设有 n 个 d 位数，每一位可能有 r 种不同的符号。这 r 种不同符号在各位上出现的频率不一定相同。根据散列表的大小，选取其中各种**符号分布均匀的若干位**作为散列地址。

- 计算各位数字中符号分布均匀度 λ_k 的公式：

$$\hat{e}_k = \sum_{i=1}^r (\hat{o}_i^k - n/r)^2$$

- 其中， $\hat{o}_i^k$ 表示第 i 个符号在第 k 位上出现的次数， n/r 表示各种符号在 n 个数中均匀出现的期望值。



计算出的 λ_k 值越小，表明在该位 (第 k 位) 各种符号分布得越均匀。

9 4 2 1 4 8 ①位, $\lambda_1 = 57.60$

9 4 1 2 6 9 ②位, $\lambda_2 = 57.60$

9 4 0 5 2 7 ③位, $\lambda_3 = 17.60$

9 4 1 6 3 0 ④位, $\lambda_4 = 5.60$

9 4 1 8 0 5 ⑤位, $\lambda_5 = 5.60$

9 4 1 5 5 8 ⑥位, $\lambda_6 = 5.60$

9 4 2 0 4 7

9 4 0 0 0 1

① ② ③ ④ ⑤ ⑥



- 若散列表地址范围有 3 位数字, 取各关键码的 ④⑤⑥ 位做为记录的散列地址。
- 数字分析法仅适用于事先明确知道表中所有关键码每一位数值的分布情况, 它完全依赖于关键码集合。如果换一个关键码集合, 选择哪几位要重新决定。



③ 除留余数法

设散列表中允许地址数为 m ，取一个不大于 m ，但最接近于或等于 m 的质数 p 作为除数，用以下函数把关键码转换成散列地址：

$$\text{hash}(key) = key \% p \quad p \leq m$$

其中，“ $\%$ ”是整数除法取余的运算，要求这时的质数 p 不是接近2的幂。



■ 数论原因：减少非完全随机关键字导致的聚集

- 如果关键字是随机分布的，那么模任何数分布都会均匀。
- 如果除数 m 是合数，且关键字与 m 有公因子，那么取模后分布会不均匀。

假设 $m = 8$ （合数），关键字都是偶数：

$key = 2, 4, 6, 8, 10, 12, 14, 16, \dots$

那么：

$$key \bmod 8 = 2, 4, 6, 0, 2, 4, 6, 0, \dots$$

结果只出现在 $\{0, 2, 4, 6\}$ 四个位置，而位置 1, 3, 5, 7 永远不会有值 $\rightarrow$ 分布不均匀。

如果 $m = 7$ （质数），关键字都是偶数：

$key \bmod 7$ 会取遍 0 到 6，因为 2 与 7 互质，序列 $2k \bmod 7$ 是周期 7 的完全排列。



对于除留余数法 $H(k) = k \bmod p$:

- 如果 p 是质数，且关键字序列 k 与 p 互质的比例很高，那么取模结果在 $0, 1, \dots, p-1$ 上分布更均匀。
- 如果 p 是合数，设 $d = \gcd(k, p)$ ，那么 $k \bmod p$ 只会取 p/d 个不同的值，而不是 p 个值，导致某些槽位永远不会被映射到。
- 质数 p 与大多数关键字序列的“公因子”可能性小，从而减少这种非均匀映射。
- 即使关键字有某种规律（如等差序列），只要该规律与 p 互质，模 p 的结果仍然会遍历 0 到 $p-1$ 。



- 示例: 有一个关键码 $key = 962148$, 散列表大小 $m = 25$, 即 $HT[25]$ 。取质数 $p = 23$ 。散列函数 $hash(key) = key \% p$, 则散列地址为
 $hash(962148) = 962148 \% 23 = 12$ 。
- 可按计算出的地址存放记录。注意, 使用散列函数计算出的地址范围是 0 到 22, 而 23、24 这几个地址实际上不能用散列函数计算出来, 只能在处理冲突时达到这些地址。



④ 平方取中法

首先计算构成关键码的标识符的内码的平方，然后按照散列表的大小取中间的若干位作为散列地址。

- 设标识符可以用一个计算机字长的内码表示。因为内码平方数的中间几位一般是由标识符所有字符决定，所以对不同的标识符计算出的散列地址大多不相同。
- 在平方取中法中，一般取散列地址为8的某次幂。例如，若散列地址总数取为 $m = 8^r$ ，则对内码的平方数取中间的 r 位。



标识符	内码	内码平方	散列地址
<i>A</i>	01	<u>01</u>	001
<i>A1</i>	0134	<u>20420</u>	042
<i>A9</i>	0144	<u>23420</u>	342
<i>B</i>	02	<u>04</u>	004
<i>DMAX</i>	04150130	<u>21526443617100</u>	443
<i>DMAX1</i>	0415013034	<u>5264473522151420</u>	352
<i>AMAX</i>	01150130	<u>135423617100</u>	236
<i>AMAX1</i>	0115013034	<u>3454246522151420</u>	652

标识符的**八进制内码**表示及其平方值和散列地址




⑤ 折叠法

此方法把关键码自左到右分成位数相等的几部分，每一部分的位数应与散列表地址位数相同，只有最后一部分的位数可以短一些。

把这些部分的数据叠加起来，就可以得到具有该关键码的记录的散列地址。

- 有两种叠加方法：

- ❖ 移位法：把各部分最后一位对齐相加；
- ❖ 分界法：各部分不折断，沿各部分的分界来回折叠，然后对齐相加。




示例: 设给定的关键码为 $key = 23938587841$,
若存储空间限定 3 位, 则划分结果为每段 3 位。
上述关键码可划分为 4 段:


239 385 878 41

- 叠加, 然后把超出地址位数的最高位删去, 仅保留最低的 3 位, 做为可用的散列地址。

移位法



分界法





- 一般当关键码的位数很多，而且关键码每一位上数字的分布大致比较均匀时，可用这种方法得到散列地址。
- 假设地址空间为 $HT[400]$ ，利用以上函数计算，取其中3位，取值范围在 $0 \sim 999$ ，可能超出地址空间范围，为此必须将 $0 \sim 999$ 压缩到 $0 \sim 399$ 。可将计算出的地址乘以一个压缩因子0.4，把计算出的地址压缩到允许范围。



(1)处理冲突的闭散列方法



任一种散列函数也不能避免产生冲突，因此选择好的解决冲突的方法十分重要。

线性探查法 (Linear Probing)

例1：假设给出一组表项，它们的关键码为 Burke, Ekers, Broad, Blum, Attlee, Alton, Hecht, Ederly。采用的散列函数是：取其第一个字母在字母表中的位置。

$$\text{Hash}(x) = \text{ord}(x) - \text{ord}('A')$$

//ord() 是求字符内码的函数



可得

$Hash(Burke) = 1$ $Hash(Ekers) = 4$

$Hash(Broad) = 1$ $Hash(Blum) = 1$

$Hash(Attlee) = 0$ $Hash(Alton) = 0$

$Hash(Hecht) = 7$ $Hash(Ederly) = 4$

- 设散列表 $HT[26]$, $m = 26$ 。采用线性探查法处理冲突, 则散列结果如图所示。

0	1	2	3	4
Attlee	Burke	Broad	Blum	Ekers
(1)	(1)	(2)	(3)	(1)
5	6	7	8	9
Alton	Ederly	Hecht		
(6)	(3)	(1)		



- 需要搜索或加入一个表项时, 使用散列函数计算关键字在表中的位置:

$$H_0 = \text{hash} (\text{key})$$

- 一旦发生冲突, 在表中顺次向后寻找下一个位置 H_i :

$$H_i = (H_{i-1} + 1) \% m, \quad i = 1, 2, \dots, m-1$$

即用以下的线性探查序列在表中寻找下一个位置:

$$H_0 + 1, H_0 + 2, \dots, m-1, 0, 1, 2, \dots, H_0 - 1$$

亦可写成如下的通项公式:

$$H_i = (H_0 + i) \% m, \quad i = 1, 2, \dots, m-1$$



例1中使用线性探查法对示例进行搜索时:

- 搜索成功的平均搜索长度为:

$$ASL_{succ} = \frac{1}{8} \sum_{i=1}^8 C_i = \frac{1}{8} (1 + 1 + 2 + 3 + 1 + 6 + 3 + 1) = \frac{18}{8}.$$

- 搜索不成功的平均搜索长度为:

$$ASL_{unsucc} = \frac{9 + 8 + 7 + 6 + 5 + 4 + 3 + 2 + 18}{26} = \frac{62}{26}.$$



例： 给定关键字序列为

19, 14, 23, 1, 68, 20, 84, 27, 55, 11, 10, 79

散列函数： $H(\text{key}) = \text{key} \% 13$

散列表空间地址为0~12,

试用线性探查法建立散列表

0	1	2	3	4	5	6	7	8	9	10	11	12
	14	1	68	27	55	19	20	84	79	23	11	10

存储的是
数据元素



- 例2：已知散列表A[0..11]，选取除留余数法设计散列函数 $H(K) = K \bmod 11$ ，关键字集合为{10, 20, 15, 17, 21, 6, 8, 25, 40, 35, 27}，采用线性探查法处理冲突，请将关键字填入下面的哈希表中，计算成功和失败时的平均查找长度ASL。

0	1	2	3	4	5	6	7	8	9	10	11
		35	25	15	27	17	40	8	20	20	

		1	1	1	1	2	6	1	1	2	
失败	2	1	12	11	10	9	8	7	6	5	4

$$ASL_{succ} = \frac{1}{11} \sum_{i=1}^{11} C_i = \frac{1}{11} (8 * 1 + 2 + 2 + 6) = \frac{18}{11}.$$

$$ASL_{unsucc} = \frac{2 + 1 + 12 + 11 + \infty + 4}{11} = \frac{75}{11}.$$



- **例3：已知关键字集合为 { 47, 7, 29, 11, 16, 92, 22, 8 } 。假设哈希函数 $H(\text{key}) = \text{key} \bmod 11$ (表长=11), 采用线性探查法处理冲突, 请将关键字填入下面的哈希表中, 计算成功和失败时的ASL。**

0	1	2	3	4	5	6	7	8	9	10



Linear Probing

- $h_i(K) = (\text{hash}(K) + i) \bmod m$
- E.g, inserting keys 89, 18, 49, 58, 69 with $\text{hash}(K) = K \bmod 10$

	Empty Table	After 89	After 18	After 49	After 58	After 69
0				49	49	49
1					58	58
2						69
3						
4						
5						
6						
7						
8			18	18	18	18
9		89	89	89	89	89

To insert 58,
probe $T[8]$, $T[9]$,
 $T[0]$, $T[1]$

To insert 69,
probe $T[9]$, $T[0]$,
 $T[1]$, $T[2]$



Quadratic Probing

- $f(i) = i^2$
- $h_i(K) = (\text{hash}(K) + i^2) \bmod m$
- E.g., inserting keys 89, 18, 49, 58, 69 with $\text{hash}(K) = K \bmod 10$

	Empty Table	After 89	After 18	After 49	After 58	After 69
0				49	49	49
1						
2					58	58
3						69
4						
5						
6						
7						
8			18	18	18	18
9		89	89	89	89	89

To insert 58,
probe $T[8]$,
 $T[9]$, $T[(8+4) \bmod 10]$
To insert 69,
probe $T[9]$,
 $T[(9+1) \bmod 10]$,
 $T[(9+4) \bmod 10]$



(2)处理冲突的开散列方法（链地址法）



- **开散列方法（链地址法）** 首先对关键码集合用某一个散列函数计算它们的存放位置。
- 若设散列表地址空间的位置从 $0 \sim m-1$ ，则关键码集合中的所有关键码被划分为 m 个子集，具有相同地址的关键码归于同一子集。我们称**同一子集中的关键码**互为**同义词**，每一个子集称为一个**桶**。
- 通常各个桶中的表项通过一个单链表链接起来，称之为**同义词子表**。



- 所有桶号相同的表项都链接在同一个同义词子表中，各链表的表头结点组成一个向量。
- 向量的元素个数与桶数一致。桶号为 i 的同义词子表的表头结点是向量中第 i 个元素。
- 示例：给出一组表项关键码 { Burke, Ekers, Broad, Blum, Attlee, Alton, Hecht, Ederly }。散列函数为： $Hash(x) = ord(x) - ord('A')$ 。



用散列函数 $Hash(x) = ord(x) - ord('A')$ 计算可得:

$$Hash(Burke) = 1$$

$$Hash(Ekers) = 4$$

$$Hash(Broad) = 1$$

$$Hash(Blum) = 1$$

$$Hash(Attlee) = 0$$

$$Hash(Hecht) = 7$$


$$Hash(Alton) = 0$$

$$Hash(Elderly) = 4$$

- 散列表为 $HT[0..25]$, $m = 26$ 。



1
2
3
4
5
6
7
8
9



$$ASL_{succ} = \frac{1 * 4 + 2 * 3 + 3 * 1}{8} = \frac{13}{8}$$

$$ASL_{unsucc} = \frac{1}{26} (3 + 4 + 1 + 1 + 3 + 1 + 1 + 2 + 1 * 18) = \frac{34}{26}$$



- 通常，每个桶中的同义词子表都很短，设有 n 个关键码通过某一个散列函数，存放至散列表中的 m 个桶中，那么每一个桶中的同义词子表的平均长度为 n / m 。
- 以搜索平均长度为 n / m 的同义词子表代替了搜索长度为 n 的顺序表，搜索速度快得多。




用不同的方法溢出处理冲突时散列表的平均搜索长度如图所示。

处 理 溢 出 的 方 法		平 均 搜 索 长 度 ASL	
		搜索成功 Sn	搜索不成功 Un (登入新记录)
闭 散 列 法	线性探查法	$\frac{1}{2} \left(1 + \frac{1}{1-\alpha} \right)$	$\frac{1}{2} \left(1 + \frac{1}{(1-\alpha)^2} \right)$
	伪随机探查法	$-\left(\frac{1}{\alpha} \right) \log_e (1-\alpha)$	$\frac{1}{1-\alpha}$
	二次探查法		
	双散列法		
链 地 址 法 (同义词子表法)		$1 + \frac{\alpha}{2}$	$\alpha + e^{-\alpha} \approx \alpha$



对给定的关键字集合，应尽可能均匀地散列到各个地址，使冲突更少

散列查找



$$H_i = (H(\text{key}) + d_i) \% m$$



- 1. 散列函数最重要的特性是:
 - A) 能够生成有序的输出
 - B) 能够将键均匀分布到整个地址空间
 - C) 能够产生加密安全的输出
 - D) 能够压缩数据大小
- 2. 在开散列（链地址法）中，发生冲突时:
 - A) 寻找下一个空闲地址
 - B) 在同一个桶内用链表存储多个元素
 - C) 重新计算整个散列表
 - D) 丢弃新插入的元素
- 3. 散列表的负载因子 α 定义为:
 - A) 表中元素个数 / 表的大小
 - B) 表的大小 / 表中元素个数
 - C) 冲突次数 / 插入操作次数
 - D) 查找长度 / 表的大小



第6章书面作业



11月20号上课前交到教室讲台

- (1) 第295 页, 6.6
- (2) 第295 页, 6.9:(1)
- (3) 第295 页, 6.10
- (4) 第296 页, 6.12